

Análise de Tempo de Tela e Estresse com Aprendizagem de Máquina

João Inácio Scrimini

17/06/2026

1 Introdução

O presente trabalho investiga a relação entre o tempo de uso de tela e indicadores de bem-estar psicológico, com o objetivo de analisar padrões e possíveis associações entre hábitos digitais e níveis de estresse. O aumento do uso de dispositivos digitais e o tempo de exposição a telas têm sido amplamente discutidos na literatura por sua possível associação com níveis elevados de estresse, ansiedade e impactos negativos no bem-estar psicológico, especialmente em jovens adultos, nos quais o uso de smartphones e redes sociais tende a ser mais intensivo e constante [Pera, 2020].

Para isso, foi utilizada uma abordagem de Aprendizagem de Máquina Supervisionada, aplicada a um problema de regressão, no qual a variável resposta representa o nível de estresse em escala de 0 a 10. O conjunto de dados utilizado foi obtido na plataforma Kaggle [Kumaresan, 2025], disponível em: <https://www.kaggle.com/datasets/adharshinikumar/screentime-vs-mentalwellness-survey-2025>. O banco de dados é composto por respostas de uma pesquisa com 400 participantes, relacionando hábitos de uso de dispositivos digitais com indicadores de saúde mental e estilo de vida, incluindo variáveis como tempo de tela, sono, atividade física e interação social.

Para a construção dos modelos, foram utilizadas as seguintes variáveis: nível de estresse (Nv_estresse, variável resposta), idade, sexo, tempo de tela em horas (Tempo_tela_h), horas de sono (Horas_dormidas), minutos de atividade física por semana (Exerc_semanal_min) e horas de interação social por semana (Social_semanal_h). A variável sexo foi derivada da variável gênero, mantendo apenas as categorias masculino e feminino. O conjunto final utilizado na modelagem contém 392 observações.

A partir desse conjunto de dados, foram aplicados métodos de regressão supervisionada, incluindo Regressão Linear, Árvore de Decisão para Regressão e Random Forest. O objetivo é comparar o desempenho desses modelos na predição do nível de estresse com base nas variáveis explicativas, avaliando sua capacidade de generalização por meio de métricas apropriadas de erro e ajuste.

2 Fundamentos Teóricos e Metodológicos

A Aprendizagem de Máquina Supervisionada consiste em um conjunto de técnicas nas quais um modelo aprende a relação entre uma matriz de covariáveis (X), cujas linhas representam as observações e as colunas as variáveis explicativas, e uma variável resposta (y), a partir de dados rotulados. O objetivo é estimar uma função $f(X)$ tal que $\hat{y} = f(X)$, minimizando o erro entre previsões e valores reais. Neste trabalho, o problema é tratado como uma tarefa de regressão supervisionada, na qual a variável resposta é contínua. Foram utilizados três métodos principais:

Regressão Linear, Árvore de Decisão para Regressão e Random Forest, além de métricas de avaliação de desempenho.

2.1 Regressão Linear

A Regressão Linear assume uma relação linear entre as variáveis explicativas e a variável resposta [Montgomery et al., 2021]. O modelo é definido por uma combinação linear das variáveis de entrada, conforme a expressão:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p,$$

em que $\hat{y}$ representa o valor predito da variável resposta.

Os parâmetros β são estimados minimizando a soma dos erros quadráticos: $\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2$, em que n é o número de observações do conjunto de dados.

Esse método busca a melhor aproximação linear dos dados, sendo interpretável e eficiente, mas limitado para relações não lineares.

2.2 Árvore de Decisão para Regressão

A Árvore de Decisão para Regressão é um método não paramétrico que particiona o espaço das variáveis explicativas em regiões disjuntas e homogêneas [Breiman et al., 2017]. Em cada particionamento, o algoritmo busca a divisão que minimiza a variabilidade dos valores da variável resposta dentro dos subconjuntos resultantes.

A predição em uma região R (subconjunto do espaço de dados correspondente a uma folha da árvore) é dada pela média dos valores observados:

$$\hat{y} = \frac{1}{|R|} \sum_{i \in R} y_i.$$

O objetivo do particionamento é minimizar o erro quadrático médio dentro das regiões. Esse método permite capturar relações não lineares e interações entre variáveis, embora seja suscetível ao sobreajuste (overfitting). O crescimento da árvore é controlado por restrições estruturais que evitam esse problema, como profundidade máxima, número mínimo de observações para realização de uma divisão e número mínimo de observações em cada folha. Tais parâmetros regulam a complexidade do modelo e impactam diretamente sua capacidade de generalização.

2.3 Random Forest para Regressão

O Random Forest é um método ensemble baseado na combinação de múltiplas árvores de decisão treinadas a partir de amostras bootstrap dos dados e de subconjuntos aleatórios das variáveis explicativas [Breiman, 2001]. A previsão final do modelo é obtida pela média das previsões individuais de cada árvore:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T \hat{y}_t,$$

em que T é o número de árvores no ensemble. A aleatoriedade reduz a variância do modelo e melhora sua capacidade de generalização, tornando-o mais robusto do que uma única árvore. O desempenho do modelo depende do número de árvores no ensemble, da profundidade das árvores individuais e da quantidade de variáveis consideradas em cada divisão, fatores que controlam o equilíbrio entre viés e variância.

2.4 Métricas de Avaliação

Para avaliar o desempenho dos modelos, foram utilizadas as métricas raiz do erro quadrático médio (RMSE) e coeficiente de determinação R^2 . O RMSE mede o erro médio entre valores reais e preditos, penalizando mais fortemente erros grandes: $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$. Valores menores indicam melhor desempenho do modelo.

Já o coeficiente de determinação R^2 mede a proporção da variância explicada pelo modelo: $R^2 = (\text{cor}(y, \hat{y}))^2$. Valores próximos de 1 indicam bom ajuste, enquanto valores próximos de 0 indicam baixo poder explicativo.

3 Aplicação

Nesta seção, são descritos a análise exploratória dos dados e a aplicação dos métodos de aprendizado de máquina utilizados no estudo.

3.1 Análise Exploratória dos Dados

A Tabela 1 apresenta as estatísticas descritivas das variáveis do estudo. De forma geral, observa-se um nível de estresse elevado na amostra (média de 8.156 em uma escala de 0 a 10), sugerindo alta carga de estresse entre os participantes. O tempo médio de tela é de 9.04 horas diárias, indicando uso intensivo de dispositivos digitais, enquanto o sono médio de 7.02 horas está próximo do recomendado para adultos. As demais variáveis apresentam maior variabilidade, especialmente a atividade física semanal (109.3 ± 70.2 minutos) e as horas de interação social semanal (7.89 ± 4.92 horas), indicando diferenças significativas entre os indivíduos nos hábitos de vida. Observa-se também uma distribuição relativamente equilibrada entre homens (170) e mulheres (222) na amostra.

Tabela 1: Resultados descritivos das variáveis em estudo e teste de normalidade de Shapiro-Wilk (SW) para as variáveis quantitativas.

Variável	Mín	Mediana	Média	Máx	DP	SW(p -valor)	NA's
Nv_estresse	0	8.8	8.156	10	2.101	<0.001	0
Idade	16	30	29.587	60	7.347	<0.001	0
Tempo_tela_h	1	9.13	9.04	19.17	2.455	0.191	0
Horas_dormidas	4.64	7.03	7.018	9.74	0.857	0.655	0
Exerc_semanal_min	0	103	109.304	372	70.201	<0.001	0
Social_semanal_h	0	7.7	7.89	23.9	4.917	<0.001	0
Sexo	n: Masculino(0) = 170				Feminino(1) = 222		

Quanto ao teste de Shapiro-Wilk, observa-se que a maioria das variáveis não segue distribuição normal ($p < 0.05$). Em contrapartida, horas de sono ($p = 0.655$) e tempo de tela ($p = 0.191$) apresentam comportamento aproximadamente normal. Além disso, não foram identificados dados faltantes (NA's) no conjunto analisado.

A matriz de correlação (Figura 1) indica uma associação positiva entre o tempo de tela e o nível de estresse ($r = 0.70$), sugerindo que maiores períodos de uso de telas tendem a estar relacionados a níveis mais elevados de estresse, e uma associação negativa entre estresse e horas de sono ($r = -0.49$), indicando que menores períodos de sono tendem a estar associados a maiores níveis de estresse. As demais variáveis apresentam correlações fracas, tanto com o nível de estresse quanto entre si.

O boxplot por sexo não indica diferenças relevantes no nível de estresse entre os grupos.




Figura 1: Gráfico de correlação de Pearson entre as variáveis quantitativas e boxplot da variável sexo em relação ao nível de estresse.

3.2 Aplicação dos métodos

Após a análise exploratória dos dados, esta subseção apresenta a metodologia empregada na construção, ajuste e avaliação dos modelos de Regressão Linear (OLS), Árvore de Decisão e *Random Forest*, bem como os resultados obtidos por meio de sua aplicação. As análises foram realizadas em ambiente R, utilizando os pacotes da biblioteca `tidymodels`.

Para avaliar a capacidade de generalização dos modelos e reduzir o risco de sobreajuste, os dados foram divididos em conjuntos de treino (80%) e teste (20%). A fim de garantir a reprodutibilidade dos resultados, utilizou-se a semente aleatória `set.seed(123)` em todas as etapas. No conjunto de treino, foi empregada validação cruzada *k-fold* com 10 partições para a otimização dos hiperparâmetros e avaliação interna dos modelos. A variável resposta foi o nível de estresse, modelado em função das demais covariáveis. A seleção das configurações finais baseou-se nas métricas RMSE e R^2 , adotando-se a minimização do RMSE como principal critério de escolha.

Foram considerados três modelos preditivos: Regressão Linear (OLS), Árvore de Decisão e *Random Forest*. A Regressão Linear foi utilizada como modelo de referência. Para a Árvore de Decisão, realizou-se a otimização da complexidade de custo (10^{-4} a 10^{-1}), da profundidade máxima da árvore (2 a 8) e do número mínimo de observações para divisão dos nós (2 a 30). No caso do *Random Forest*, foram ajustados o número de preditores selecionados em cada divisão (1 a 6), o número mínimo de observações por nó (2 a 30) e a quantidade de árvores da floresta (100 a 500). A busca pelos hiperparâmetros foi conduzida por meio de uma grade regular com quatro níveis para cada parâmetro. Com base no menor RMSE obtido durante a validação cruzada, foram selecionadas, para a Árvore de Decisão, uma profundidade máxima de 4 níveis, complexidade de custo igual a 10^{-4} e número mínimo de 20 observações para divisão dos nós. Para o *Random Forest*, foram selecionadas 200 árvores, 30 observações mínimas por nó e 6 preditores candidatos em cada divisão.

A Figura 2 apresenta a relação entre os valores observados e preditos para os três modelos. A Árvore de Decisão apresentou o melhor desempenho preditivo, com $RMSE = 1.302$ e $R^2 = 0.627$, superando a Regressão Linear ($RMSE = 1.360$, $R^2 = 0.604$) e o *Random Forest* ($RMSE = 1.363$, $R^2 = 0.605$). Observa-se, contudo, um padrão comum aos três métodos. Para indivíduos com menores níveis de estresse, as predições tendem a ser superiores aos valores observados, enquanto para aqueles com maiores níveis ocorre o comportamento inverso, com predominância de subestimações. As regiões destacadas na Figura 2 evidenciam esse padrão, indicando uma tendência dos modelos em produzir estimativas mais próximas da média da distribuição. Em contrapartida, esse comporta-

mento é menos evidente para níveis de estresse entre 8 e 9 pontos, aproximadamente, faixa na qual se observa maior proximidade entre os valores observados e preditos. Entre os modelos avaliados, a Árvore de Decisão mostrou-se mais eficaz em reduzir esse efeito, especialmente nos extremos da variável resposta, onde os erros de predição foram visivelmente menores.




Figura 2: Desempenho preditivo dos modelos com base nos valores observados e preditos.




Figura 3: Importância das covariáveis nos modelos avaliados.

A Figura 3 apresenta os coeficientes estimados pela Regressão Linear e as medidas de importância das variáveis para a Árvore de Decisão e o *Random Forest*. No modelo linear, apenas horas de sono e tempo de tela apresentaram associação estatisticamente significativa com o nível de estresse ($p < 0.001$). As estimativas indicam uma redução média de 0.658 unidades no nível de estresse para cada hora adicional de sono e um aumento médio de 0.511 unidades para cada hora adicional de tempo de tela, confirmando as tendências observadas na análise exploratória. Nos modelos baseados em árvores, observou-se um padrão consistente com os resultados da Regressão Linear. Tempo de tela e horas de sono foram as variáveis de maior relevância preditiva, com destaque para o tempo de tela, que apresentou importância superior à das demais covariáveis. Em contraste, as demais variáveis contribuíram de forma marginal para as predições, apresentando medidas de importância próximas de zero.

Considerando seu melhor desempenho preditivo, a estrutura final da Árvore de Decisão é apresentada na Figura 4. As divisões observadas ao longo da árvore refletem a influência das variáveis identificadas como mais relevantes na etapa anterior, permitindo visualizar como diferentes combinações de tempo de tela e horas de sono contribuem para a discriminação dos níveis de estresse. Observa-se que os maiores índices de estresse são encontrados em indivíduos com mais de 8.5 horas de tempo de tela e menos de 7.8 horas de sono, apresentando níveis de estresse superiores a 8.6.




Figura 4: Estrutura da Árvore de Decisão com melhor desempenho preditivo.

4 Conclusão

Os resultados indicaram que o tempo de tela e as horas de sono foram as variáveis mais relevantes para a predição do nível de estresse, resultado consistente entre os diferentes métodos de modelagem empregados. Entre os modelos avaliados, a Árvore de Decisão apresentou o melhor desempenho preditivo, alcançando o menor RMSE e o maior R^2 . Embora todos os modelos tenham apresentado tendência à superestimação de níveis mais baixos de estresse e à subestimação de níveis mais elevados, esse comportamento foi menos pronunciado na Árvore de Decisão. De modo geral, os resultados ressaltam a importância dos hábitos de sono e do tempo de exposição às telas, indicando que menos horas dormidas e maior tempo de tela estão associados a níveis mais elevados de estresse na população analisada.

Referências

- Leo Breiman. Random forests. *Machine learning*, 45(1):5–32, 2001.
- Leo Breiman, Jerome Friedman, Richard A Olshen, and Charles J Stone. *Classification and regression trees*. Chapman and Hall/CRC, 1 edition, 2017.
- Adharshini Kumaresan. Screen time vs mental wellness survey – 2025, 2025. URL <https://www.kaggle.com/datasets/adharshinikumar/screentime-vs-mentalwellness-survey-2025>. Acessado em 04 jun. 2026.
- Douglas C Montgomery, Elizabeth A Peck, and G Geoffrey Vining. *Introduction to linear regression analysis*. John Wiley & Sons, 2021.
- Aurel Pera. The psychology of addictive smartphone behavior in young adults: Problematic use, social anxiety, and depressive stress. *Frontiers in psychiatry*, 11:573473, 2020.